

Video de alta calidad en nuestra propia GPU

Plan por etapas y corrección de tres puntos del Manual técnico 7. Qué se puede mover hoy a máquinas nuestras, qué todavía no, cuánto cuesta cada etapa y en qué punto exacto se decide seguir o parar.

Nada de esto se ha gastado ni encendido

José pidió el plan antes que la prueba. No hay ninguna máquina levantada, ningún modelo descargado y ningún cargo generado por este documento. Lo único que se ejecutó fueron consultas de solo lectura al catálogo y a las cuotas de nuestra cuenta de AWS, que no cuestan nada.

Documento técnico 8 · No es un documento de Junta. Se lee después del Manual 7 y no lo reemplaza.

0 · Corrección: por dónde empezar

Este documento se escribió para contestar «¿podemos hacerlo en máquina nuestra?». La respuesta sigue siendo que sí y todo lo que viene después sigue siendo válido. Pero después de leerlo preguntaste otra cosa: **si sale mejor pagar mensual o por lo que se ocupe, y sobre todo que no haya que estar esperando a que encienda**. Esa segunda mitad cambia por dónde se empieza.

La máquina propia no es lenta de generar: es lenta de EMPEZAR

Una g6e.xlarge tarda entre uno y dos minutos en arrancar, y la primera vez hay que instalar los modelos —descargar entre 30 y 60 GB de pesos— antes de la primera imagen. Después va rápido, pero eso es exactamente la espera que dijiste que no querías. Y si se deja encendida para no esperar, cuesta 1 340 USD al mes aunque no se use: en la tabla de costos de la sección 6 ese es el riesgo real del plan, y con esta forma de trabajar deja de ser un riesgo y pasa a ser lo que va a ocurrir.

Por eso la etapa 1 no se hace en máquina propia. Se hace en un servicio que cobra por segundo generado y no por hora encendida, sin nada que arrancar:

	Máquina propia (este documento)	Por lo que se ocupe
Esperar antes de la primera toma	1–2 min de arranque + 20–40 min de instalación la primera vez	Ninguna. Se manda y responde
Lo que se paga	1,861 USD por hora encendida, se use o no	Por segundo generado: 0,04 USD/s a 1080p
Entrenar un LoRA de una cara	8–15 USD y hay que montar el entorno	9,60 USD · 2 000 pasos · 20–40 min · los pesos se bajan
Olvidarse de apagar	1 340 USD al mes	Imposible: no hay nada encendido
Cuándo conviene	Cuando ya se genera todos los días y en volumen	Ahora, para medir si los LoRA sostienen la cara

Y la máquina propia no se descarta: se pospone hasta que haya un número

El punto de equilibrio entre las dos formas depende de cuántos segundos de video se generan al mes, y ese dato hoy no existe —lo dice la sección 6 de este mismo documento—. Haciendo la etapa 1 por segundo generado, la factura del primer mes ES esa medición: si sale que se está gastando más de lo que costaría la máquina encendida, entonces sí conviene levantarla, y todo el plan de las secciones 3 a 7 está escrito y listo para ese día. Al revés no: levantar la máquina primero es pagar por hora para averiguar si hacía falta pagar por hora.

Todo lo demás de este documento se mantiene: el LoRA por personaje sigue siendo la única forma de sostener una cara entre tomas —25 a 30 fotos, no una imagen de referencia—, el reparto entre lo que lleva cara y lo que no sigue siendo el correcto, y el montaje sigue resuelto en Remotion. Lo único que cambia es **DÓNDE** corre la etapa 1.

1 · Lo que el Manual 7 resolvió bien y aquí no se toca

Un documento que corrige otro tiene la obligación de decir primero qué deja en pie. Todo esto sigue vigente sin cambios, y quien produzca el próximo comercial debe seguirlo tal como está escrito allí:

- **La marca se compone en post.** El modelo pone la fotografía; el contador, los subtítulos, las cartelas y el monograma los dibuja el código. Un carácter de más en un logotipo generado mata el remate, y una corrección de texto tiene que costar un render y no una generación.
- **Referencias de 1440×1440 normalizadas**, con el mismo encuadre, fondo y luz. A un modelo no se le describe un logotipo: se le entrega.
- **Un solo src/guion.ts** con todos los tiempos, cifras y colores. Ningún otro archivo con un número a mano.
- **Remotion para el montaje, y Remotion Lambda para el render.** Es la pieza de AWS que el proyecto de verdad necesita: sin servidor encendido, sin cuota que pedir, céntimos por render. Nada de este documento la cambia.
- **Los diecisiete errores de la sección 7**, en particular los de criterio: la víctima no ve el robo, la física manda sobre la estética, y ver la referencia que nombró el cliente antes de escribir una línea.

El principio que sobrevive intacto y que además ordena este plan

La generación de imagen y el montaje son dos oficios distintos y se decidieron por separado en el Manual 7. Esa separación es la que permite cambiar de modelo sin tocar el montaje. Todo lo que sigue afecta únicamente a la mitad de la generación.

2 · Tres correcciones al Manual 7

2.1 · La pregunta estaba mal planteada

El Manual 7 buscó un modelo base que sostuviera la cara de una persona entre tomas con solo el prompt y una imagen de referencia, probó Wan 2.2, HunyuanVideo y LTX-Video, y concluyó que ninguno lo hace. La conclusión es cierta y hay que agrandarla: **ningún modelo lo hace por esa vía**. Las comparativas de 2026 miden que tanto Wan 2.2 como HunyuanVideo 1.5 pierden la identidad del personaje pasados unos cinco a siete segundos, y ese es el techo práctico de un clip en cualquiera de los dos.

Pero en el mundo de los modelos abiertos la identidad no se resuelve cambiando de modelo base. Se resuelve **entrenando un LoRA de esa persona**: un archivo pequeño, de unos pocos cientos de megas, que se entrena con veinticinco a treinta fotos de la misma cara en ángulos y luces distintos y que después se le acopla al modelo en cada generación. La documentación de entrenamiento de Wan 2.2 lo dice sin rodeos: sin LoRA la cara deriva —cambia la nariz, la forma del ojo, la estructura facial a media toma—, y un LoRA bien entrenado da consistencia más fiable que cualquier prompt o imagen de referencia.

Esa palanca no aparece en ninguna parte del Manual 7. Es la corrección de fondo, porque cambia el veredicto: lo que se había declarado imposible es un problema resuelto por otro camino.

Y hay una ventaja que no es técnica

Un LoRA se entrena una vez y queda. El personaje deja de ser algo que hay que volver a convencer al proveedor de que reproduzca en cada generación y pasa a ser un archivo nuestro, versionado en el repositorio, que funciona igual dentro de un año. Con Seedance, la cara del comercial vive en la infraestructura de ByteDance.

2.2 · La evaluación de LTX está dos generaciones vieja

El Manual 7 descarta «LTX-Video (Lightricks)» por calidad insuficiente para una pieza de marca. Ese juicio era correcto para el modelo que probó, pero ese modelo ya tiene dos sucesores:

Versión	Salió	Qué trae
LTX-Video	el que probó el Manual 7	Cabía en 24 GB. Calidad por debajo de lo que pide una marca.
LTX-2.3	5 de marzo de 2026	22 mil millones de parámetros (14B de video y 5B de audio). Clips de hasta 20 segundos. Adaptadores IC-LoRA con condicionamiento de pose, profundidad y bordes.
LTX-2.5	11 de agosto de 2026	Pesos abiertos. Audio y video en una sola pasada, que ningún otro abierto hace. Uso gratuito por debajo de 10 millones de dólares de facturación anual.

Los clips de veinte segundos importan más de lo que parece. El Manual 7 anota como defecto de Veo 3 que sus tomas de cuatro a ocho segundos obligan a diez o más generaciones para un comercial de sesenta y tres. Veinte segundos por toma cambia esa aritmética entera.

Una trampa que hay que decir por su nombre

Circulan páginas ofreciendo descargas de «Wan 2.7». No existe: los pesos abiertos oficiales de Wan se detienen en la 2.2, y lo que esas páginas distribuyen no es lo que dicen. Antes de bajar un modelo hay que verificar que salga del repositorio del fabricante en Hugging Face y de ningún otro sitio.

2.3 · El trámite de cuota que el Manual 7 temía no aplica a nuestra cuenta

El Manual 7 avisa, con razón como advertencia general, que las familias G y P de AWS vienen con cuota cero en una cuenta nueva y que el aumento tarda de horas a días, y concluye que ese trámite hay que abrirlo antes de prometer una fecha. **En la cuenta de Orden Global ese trámite ya está hecho.** Medido hoy con `aws service-quotas list-service-quotas` sobre `us-east-1`:

Cuota	Código	Valor	Qué significa
Instancias G y VT bajo demanda	L-DB2E81BA	384 vCPU	Podemos encender una GPU hoy mismo, sin pedir nada.
Instancias P bajo demanda	L-417A185B	384 vCPU	También las de entrenamiento, aunque no hacen falta.
G y VT en Spot	L-3819A6DF	0	Esto sí está en cero. No hay GPU a precio de Spot sin pedirlo antes.

Que el cupo bajo demanda esté abierto también se comprueba solo: la máquina del cerebro de ULTRON es una g5.xlarge con una A10G y lleva semanas encendida.

3 · Las máquinas, con precios leídos hoy

Los precios del Manual 7 eran aproximados y pedía verificarlos antes de comprometer nada. Se verificaron con la API de precios de AWS para us-east-1, Linux, tenencia compartida. Coinciden con los suyos hasta el céntimo, así que su tabla era buena:

Instancia	GPU y VRAM	CPU y RAM	USD/hora	Para qué
g6e.xlarge	L40S · 45 GB	4 vCPU · 32 GB	1,861	La recomendada. Entra Wan 2.2 de 14B y LTX-2.5 sin cuantizar, y la misma máquina entrena los LoRA.
g6e.2xlarge	L40S · 45 GB	8 vCPU · 64 GB	2,242	La misma GPU con el doble de CPU y memoria. Solo si el cuello resulta ser el preprocesado, cosa que hoy no sabemos.
g5.2xlarge	A10G · 22 GB	8 vCPU · 32 GB	1,212	Obliga a cuantizar el modelo grande. Ahí es donde se pierde el rostro: es el error que el propio Manual 7 documentó con Wan 2.2 de 5B.
g6.xlarge	L4 · 22 GB	4 vCPU · 16 GB	0,805	La más barata con GPU. Sirve para probar el circuito y para modelos chicos, no para la toma final.

Por qué no la barata

La tentación es empezar por la g6.xlarge o la g5.2xlarge, que cuestan la mitad. Con 22 GB de VRAM hay que cuantizar el modelo de 14B para que entre, y cuantizar es exactamente lo que degrada primero: la cara. El Manual 7 ya pagó ese precio con Wan 2.2 de 5B cuantizado y lo anotó como «calidad insuficiente para rostros». Ahorrar un dólar por hora para volver a medir el mismo fracaso no es ahorrar.

Y se mantiene sin discusión lo que el Manual 7 ya dejó claro: **los siete nodos de la cadena 5550 no se tocan**. No tienen GPU, están dimensionados para firmar bloques y llevan la cadena de la empresa encima. La infraestructura de video va en máquinas aparte de la misma cuenta.

4 · Qué se puede mover hoy y qué todavía no

La respuesta honesta no es «sí» ni «no», es una raya en medio del trabajo. De un lado de la raya los modelos abiertos ya están a la altura; del otro, todavía no.

Tipo de toma	¿A GPU propia?	Por qué
Producto, mineral, objeto, textura, planos abstractos, movimientos de cámara sobre cosas quietas	Sí, hoy	No hay rostro que sostener. El propio Manual 7 ya concedía que Nova Reel y Luma sirven «para planos de objeto o abstractos». Los abiertos están por encima de esos dos.
Tomas con personas, con un LoRA entrenado por personaje	Probable, hay que medirlo	El LoRA resuelve la identidad. Lo que falta comprobar es si el fotorrealismo de piel y ojos de Wan 2.2 o LTX-2.5 aguanta al lado de Seedance en la misma pantalla. Eso no se decide leyendo: se genera el mismo plano con los dos y se miran juntos.
Tomas con personas, sin LoRA, solo con imagen de referencia	No	Es lo que el Manual 7 midió y descartó, y sigue siendo cierto.
Montaje, contador, cartelas, subtítulos, sonido, render	Ya está resuelto	Remotion Lambda. No necesita GPU ni cambia nada.

De ahí sale la recomendación de fondo, que no es sustituir a Seedance de golpe sino **un reparto**: lo que no lleva cara se genera en máquina nuestra desde la primera semana, y las tomas con personas siguen en Seedance mientras se entrenan y se miden los LoRA. Si la etapa 1 sale bien, se cruzan; si sale mal, no se ha roto nada y se sigue produciendo igual que hoy.

5 · El plan, por etapas, con su puerta de decisión

Cada etapa termina en una pregunta de sí o no. Ninguna compromete a la siguiente.

0 Reunir el material — 0 USD, no hace falta ninguna máquina

De veinticinco a treinta fotografías por cada personaje que deba repetirse entre tomas: ángulos distintos, luces distintas, expresiones distintas, sin gafas de sol ni nada que tape la cara. Esto no lo puede hacer nadie más que ustedes y es lo único que bloquea todo lo demás. Sin este material, las etapas siguientes no tienen con qué empezar. **Puerta:** ¿están las fotos de al menos un personaje?

1 La prueba que decide — un día de máquina, entre 20 y 45 USD

Se levanta una g6e.xlarge, se instalan Wan 2.2 con VACE y LTX-2.5, se entrena el LoRA del primer personaje y se generan DOS O TRES PLANOS QUE YA EXISTEN en el comercial hecho con Seedance — los mismos, no otros parecidos. Se ponen lado a lado y se miran. La máquina se apaga al terminar y deja de costar. **Puerta:** ¿aguanta la comparación en una pantalla grande? Lo decide José mirando, no una métrica.

2

Los LoRA del reparto — medio día de máquina por personaje

Un LoRA por cada persona con nombre del comercial. Se guardan en el repositorio como cualquier otro archivo del proyecto, versionados, y se reutilizan en todas las piezas que vengan. Este es el activo que queda.

Puerta: ¿cada cara se reconoce como la misma en seis planos distintos?

3

Producción por reparto — la máquina se enciende solo cuando se genera

Lo que no lleva cara y las tomas con LoRA aprobado, en máquina nuestra. El resto sigue en Seedance sin ninguna prisa por moverlo. **Puerta:** ¿el coste por pieza terminada bajó de verdad, medido, no estimado?

4

El montaje — sin cambios

Remotion y Remotion Lambda exactamente como los dejó el Manual 7. Céntimos por render y sin ninguna máquina encendida.

6 · Lo que cuesta, y lo que no puedo decirte todavía

Concepto	Coste	Nota
Etapas 1, la prueba completa	20 – 45 USD	Entre 10 y 24 horas de g6e.xlarge a 1,861 USD/hora, incluyendo el rato que se pierde instalando. Se apaga al terminar.
Un LoRA por personaje	8 – 15 USD	Entre cuatro y ocho horas de la misma máquina. Se paga una vez por cara.
Almacenamiento en S3	unos pocos USD al mes	Modelos, LoRA, clips crudos y máster. Es el único gasto permanente.
Render del montaje	0,01 – 0,05 USD por render	Remotion Lambda, tal como lo midió el Manual 7.
Máquina encendida sin usarse	1 340 USD al mes	Dejar la g6e.xlarge prendida y olvidada. El riesgo económico real de este plan no es el precio de la GPU: es olvidarse de apagarla.

El punto de equilibrio contra Seedance no lo puedo calcular hoy, y prefiero decirlo

Haría falta saber cuántos segundos de video genera una L40S por hora con estos modelos, y eso no es un dato que se pueda leer en ninguna parte con honestidad: depende de la resolución, de los pasos de muestreo y del modelo. La etapa 1 lo mide de paso, y recién entonces se puede poner el número al lado del plan de Seedance y compararlos. Cualquier cifra que ponga antes de esa medición sería inventada.

7 · Lo que puede salir mal

Un plan sin esta sección es un folleto de ventas.

Riesgo	Qué hacemos
Que la calidad no alcance. Es el riesgo principal y es real: hoy los abiertos siguen por debajo de Seedance en fotorrealismo de rostro.	Por eso la etapa 1 cuesta menos de cincuenta dólares y se decide mirando dos planos iguales lado a lado. Es barata a propósito.
Que 45 GB de VRAM se queden cortos. LTX-2.5 y Wan de 14B entran, pero sin holgura.	La g6e.2xlarge tiene la misma GPU. Si el problema es de VRAM y no de CPU, subir de talla no lo arregla y hay que ir a varias GPU, que es donde el Manual 7 ya dijo que el coste por iteración deja de compensar.
Las licencias. Wan 2.2 es Apache 2.0; LTX-2.5 es gratis por debajo de 10 M USD de facturación; sobre HunyuanVideo 1.5 las fuentes se contradicen — una dice Apache 2.0 y otra «licencia comunitaria de Tencent».	Antes de usar cualquiera de los tres en una pieza comercial hay que leer el archivo de licencia del repositorio oficial, no un artículo. Y guardarlo con la fecha en que se leyó.
El LoRA de una cara real es un dato biométrico. No es un detalle legal menor para una empresa que hace verificación de identidad.	Consentimiento por escrito y firmado de cada persona antes de entrenar su LoRA, diciendo para qué se usa y por cuánto tiempo. Se guarda con el archivo.
No hay GPU en Spot. Esa cuota está en cero, y Spot es lo que abarataría las corridas largas de entrenamiento.	Con el volumen de este plan no hace falta. Si algún día se entrenan muchos LoRA seguidos, se pide el aumento antes, no en medio.
Olvidarse una máquina encendida.	Etiqueta de apagado automático y una alarma de facturación desde el primer día. Cuesta cero y evita el único gasto grande que este plan puede producir.

8 · Lo que no recomiendo, y por qué

- **Sustituir Seedance de golpe.** Hoy sigue siendo mejor en rostro. Lo que se propone es dejar de depender de él para todo, no dejar de usarlo.
- **Las máquinas de varias GPU** (g6e.12xlarge a 10,5 USD/hora, p4d a 32,8). El Manual 7 ya lo razonó bien: el proceso exige muchas repeticiones y ahí el coste por iteración manda sobre la potencia.
- **Entrenar un modelo propio desde cero.** No aplica y no aplicará en el horizonte de este proyecto.
- **Los nodos de la cadena como máquinas de render.** Dicho en el Manual 7 y se repite aquí porque es la tentación obvia cuando se ve que hay siete máquinas encendidas.
- **Empezar por la GPU barata para «ahorrar en la prueba».** Explicado en la sección 3: mediría el fracaso que ya conocemos.

9 · Lo que hace falta para arrancar

Dos cosas, y una es de ustedes:

Qué	De quién	Sin esto...
De 25 a 30 fotos de un personaje, en ángulos y luces distintos	José / Orden Global	La etapa 1 no puede empezar. Es el único bloqueo real del plan.
Autorización para gastar entre 20 y 45 dólares de GPU	José	No se enciende nada. Este documento no gastó un céntimo.

La respuesta corta a la pregunta que originó este documento

Sí, se puede hacer video de alta calidad en máquinas nuestras, y la cuenta de AWS ya está lista para ello. Pero no porque haya aparecido un modelo nuevo que lo resuelva solo: porque la identidad de un personaje se resuelve entrenando un LoRA, que es un camino que el Manual 7 no consideró. Lo que falta por saber es si el fotorrealismo alcanza, y eso cuesta menos de cincuenta dólares averiguarlo con certeza en vez de discutirlo.

Documento técnico 8 · Orden Global · 6 de septiembre de 2026

Las cuotas y los precios de AWS se midieron el día de la fecha contra la cuenta de la empresa con `aws service-quotas`, `aws ec2 describe-instance-types` y `aws pricing get-products`. Las fechas de publicación y las características de los modelos salen de fuentes públicas consultadas el mismo día y deben reverificarse antes de comprometer una fecha: este campo cambia de mes a mes, que es precisamente lo que le pasó al Manual 7.